

УДК 004.896

РЕШЕНИЕ ЗАДАЧИ КЛАССИФИКАЦИИ ТОМАТОВ ПО СПЕЛОСТИ НА ОСНОВЕ РАСПРЕДЕЛЕНИЯ ЦВЕТА С ПОМОЩЬЮ НЕЙРОННОЙ СЕТИ

А.Д. Кулакова, В.А. Галкин, А.В. Макаренко

В докладе представлено решение задачи классификации томатов, выращиваемых в условиях промышленных теплиц, по четырем степеням спелости. Разработана архитектура полносвязной нейронной сети. В качестве признаков используются статистические характеристики сегментированного изображения томата в цветовом пространстве HSV, в частности гистограмма распределения цветового тона.

Ключевые слова: классификация, глубокое обучение, сельское хозяйство.

Введение. Развитие науки и техники, в частности технологий компьютерного зрения и глубокого обучения привело к возможности решения широкого спектра прикладных задач. Актуальным и перспективным направлением является автоматизация технологических процессов в агропромышленности, в частности решение задачи классификации объектов агрокультур по их спектральным характеристикам [1, 2, 3]. Представляемая работа будет нацелена на решение этой задачи, а именно классификации помидоров по сортам спелости.

Обзор существующих подходов. Выделяют две основные группы методов решения поставленной задачи, которые имеют общий принцип, но отличаются подходом к формированию пространства признаков для последующей классификации. Общий конвейер решения состоит из: локализации целевого объекта, сегментации (отделение объекта от общего фона), преобразования выделенного объекта в пространство признаков и применения алгоритмов классификации.

В методах первой группы пространство признаков формируется “вручную” экспертом. Так, в работе [4] с помощью SVM решается задача бинарной классификации (спелый/не спелый), достигнутая точность по метрике accuracy 97.74%. В качестве признаков объекта выступали статистические моменты отсегментированного в RGB изображения. В работе [5] использовался алгоритм SVM в пространстве цветовой карты в HSV для многоклассовой классификации (красный, зеленый, промежуточный), достигнутая точность по метрике accuracy 99.81%.

Методы второй группы используют нейросетевые технологии для автоматического формирования пространства релевантных признаков. В работе [6] предложено комбинирование глубокой свёрточной нейронной се-

ти и плоских моделей классификации, таких как: KNN и SVM. В работе [7] представлено решение на основе сверточной нейронной сети, классификация производится по 3 степени зрелости (красный, зеленый, желтый), accuracy составляет 99.67%.

Набор данных. Исходные данные представляют собой набор фотосетов, каждый из которых состоит из множества фотографий томата. Количество снимков одного томата может варьироваться от 3 до 40. Съемка производилась при естественном и искусственном освещении в различных ракурсах с использованием трех различных фотоаппаратов: Canon PowerShot G7X Mark II, Canon EOS 550 и Canon EOS 600D. Изображения томатов переведены из цветового пространства RGB (red, green, blue) в HSV (hue, saturation, value). Данное пространство позволяет разделить цветовой тон от насыщенности и яркости.

Вариации спелости томатов были сформированы в 4 класса, которые отражают степень их зрелости: зеленый (рис. 1), слабо-бурый (рис. 2), сильно-бурый (рис. 3) и красный (рис. 4).

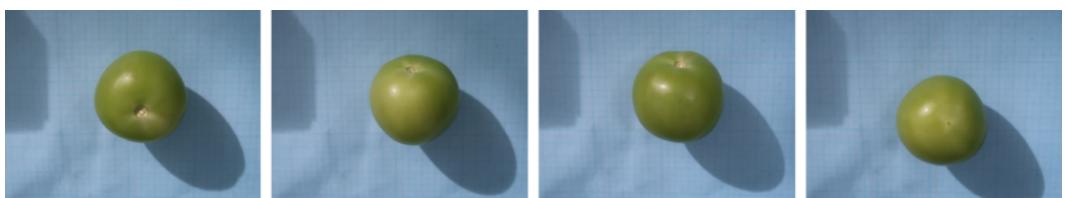


Рис. 1. Зеленый томат



Рис. 2. Слабо-бурый томат

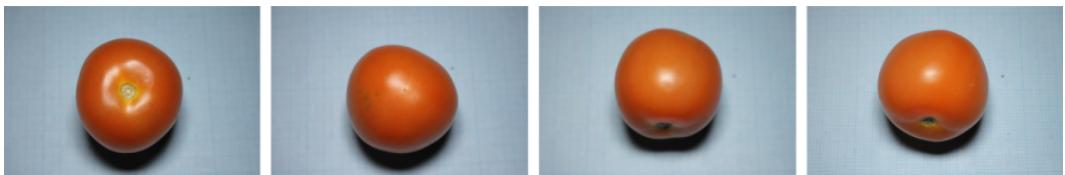


Рис. 3. Сильно-бурый томат



Рис. 3. Красный томат

Постановка задачи и подход. Пусть задано множество объектов X и множество допустимых ответов Y , представляющих собой метки классов. Существует неизвестное вероятностное распределение на множестве $X \times Y$ с плотностью $p(x, y)$. Задача заключается в поиске совместной плотности распределения объектов и ответов $\varphi(x, y, \theta)$, аппроксимирующей неизвестную плотность $p(x, y)$. При этом, требуется определить значение векторы параметров θ , при котором выборка данных $X^l = (x_i, y_i)_{i=1}^l$ из множества $X \times Y$ максимально правдоподобна, то есть наилучшим образом согласуется с моделью плотности.

Подход к решению задачи состоит из трех частей: сегментация объекта, формирование пространства признаков, обучение и дальнейшее использование классификатора.

Для сегментации объекта использовалась двухшаговая стратегия: грубая сегментация с использованием метода водораздела и последующее уточнение маски с применением глубокой свёрточной нейронной сети cascadePSP [5].

Определим пространство признаков. В текущей задаче ключевым признаком является цвет томата. В связи с тем, что поверхность томата может иметь неоднородный окрас, для принятия решения о спелости необходимо несколько фотографий с разных ракурсов. В качестве признаков объекта выбраны столбцы нормированной гистограммы распределения по цветовому тону Ие (количество столбцов – 100). Такой подход позволяет учесть все изображения томата вне зависимости от их количества, а также дискретизировать цвета, имеющиеся на поверхности помидора и использовать информацию о частоте появления конкретного оттенка цвета. Также, в качестве признаков использованы медианы значений по компонентам Saturation и Value.

В качестве классификатора была разработана архитектура полносвязной нейронной сети, подробное описание которой будет проведено в следующих разделах.

Анализ выборки. На рис. 4 приведены графики данных гистограмм. Значения цветового тона лежат в диапазоне от 0 до 360, которые были нормированы и приведены к диапазону 0-1. В скобках у каждого класса обозначено количество томатов, на основе которых была построена гистограмма. Суммарное количество целевых объектов – 1094.

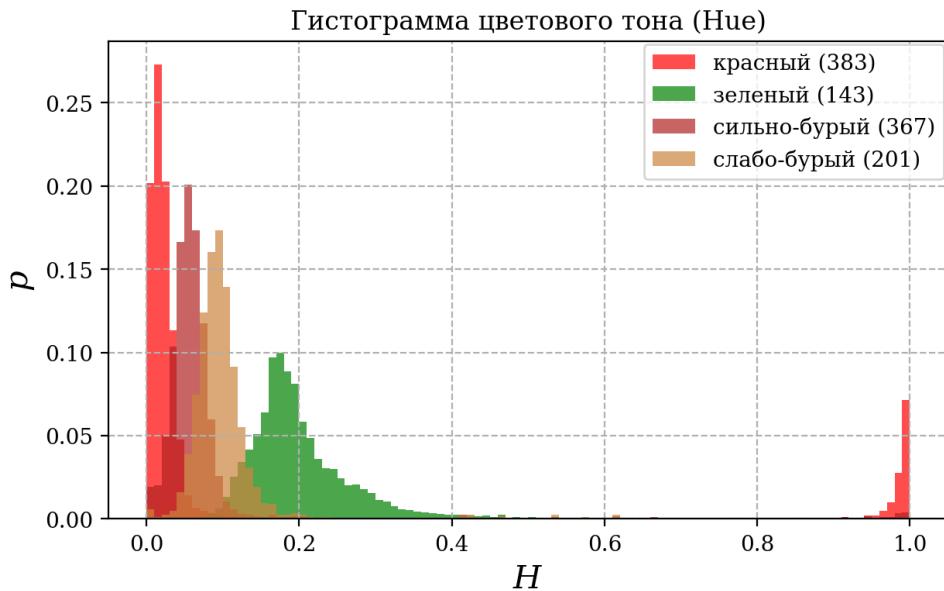


Рис. 4. Анализ набора данных

В таблице 1 приведены данные о межклассовом пересечении гистограмм распределений цветового тона. Наибольшее пересечение наблюдается между классами сильно-бурый/слабо-бурый и красный/сильно-бурый.

Таблица 1

Пересечение гистограмм классов

Классы	Пересечение, %
Красный/зеленый	2
Красный/сильно-бурый	29
Красный/слабо-бурый	7
Зеленый/сильно-бурый	6
Зеленый/слабо-бурый	19
Сильно-бурый/слабо-бурый	40

Стоит отметить, что не все интервалы в диапазоне возможных значений компоненты H (рис. 5) равнозначны применительно к текущей задаче.



Рис. 5. Шкала Hue

Так, например, цветовые тона голубого, синего и пурпурного имеют минимальные значения эмпирической вероятности, рис. 4, так как анализируемый набор данных содержит томаты, цветовое разнообразие которых ограничено. По этой причине, при обучении использованы данные не всех 100 столбцов гистограммы распределения цветового тона, а 61, рис. 6. Общее количество признаков (с учетом медиан по Saturation и Value) 63.

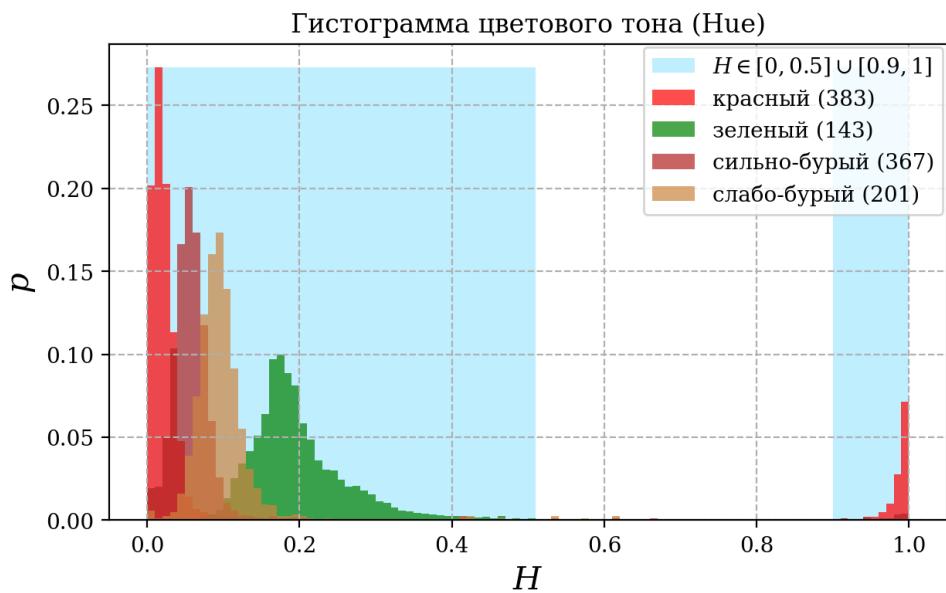


Рис. 6. Используемые столбцы гистограммы (обозначены голубым)

Нейронная сеть. Для решения поставленной задачи была разработана нейронная сеть, представляющая собой многослойный перцептрон, архитектура которого приведена на рис. 7. Количество обучаемых параметров нейронной сети – 1196.

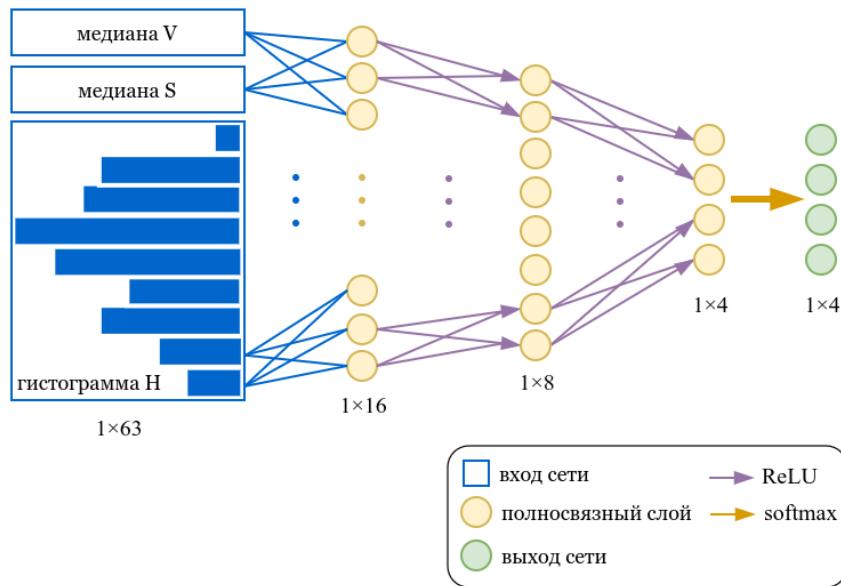


Рис. 7. Архитектура сети.

Обучающая выборка объёмом в 1094 объектов разделена на тренировочный и тестовый наборы в соотношении 75% и 25% и составили 820 и 274 томата, соответственно.

В качестве функции потерь была использована многоклассовая перекрестная энтропия. Для обучения была использована следующая стратегия обучения: оптимизатор Adam, batch size – 64, количество эпох 35, скорость обучения (learning rate) изменялась в соответствии с расписанием (stepLR) рис. 8.

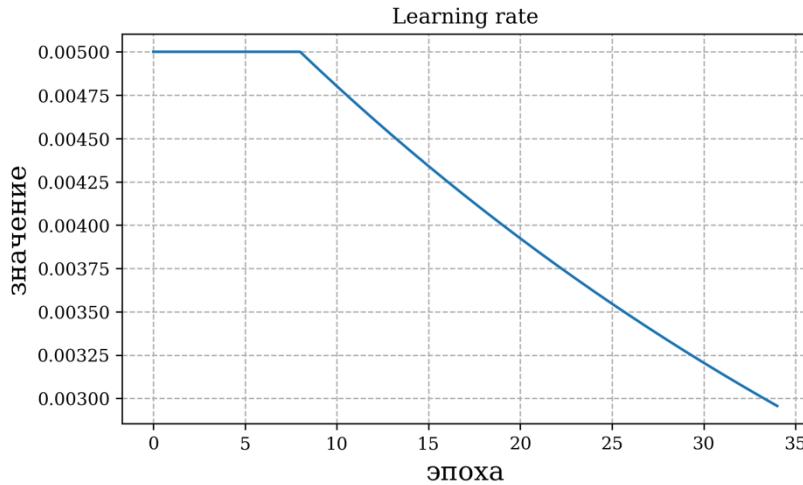


Рис. 8. Расписание learning rate.

Результаты обучения. Для оценивания качества полученных моделей использовалась метрика F1. С целью повышения устойчивости полученных результатов было произведено 10 повторных запусков нейронной сети с различной начальной инициализацией. По результатам повторных запусков отбиралась наиболее точная модель и эпоха по метрике F1. Результаты полученного решения приведены в таблице 2.

Таблица 2

Точность решения

Набор/оценка	CE Loss	F1 score
Тренировочный	0.917	0.877
Тестовый	0.897	0.934

Результирующая точность на тестовой выборке достигает 0.934.

Проведен анализ ошибок классификации, на основе которого составлена матрица ошибок (см. рис. 9). По полученным результатам можно заметить, что наибольшее количество ошибок приходится на пары классов: сильно-бурый/красный и сильно-бурый/слабо-бурый классы. Полученные ошибки согласуются с пересечением классов, представленным в таблице 1. Таким образом, возникает и актуализируется задача калибровки цвета, с целью возвращения истинной цветовой композиции.

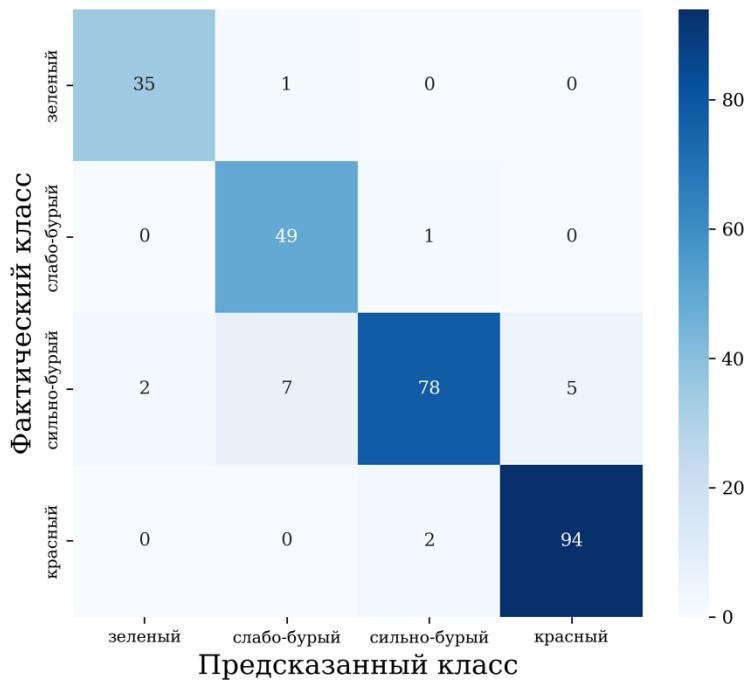


Рис. 8. Матрица ошибок

Заключение. В представленной работе рассмотрена проблема классификации томатов по спелости. Предложенный подход заключается в аппроксимации плотности распределения $p(x, y)$ спектральных характеристик объектов и меток классов спелости с использованием многослойной полносвязной нейронной сети. Результирующая точность полученного решения достигает 0.934 по метрике F1.

Основным ограничением данной работы является объем доступных данных. По этой причине проведение дальнейших исследование требует увеличение выборки.

Последующие исследования будут направлены на модификацию полученного решения с целью повышения качества и устойчивости, исследование возможности применимости других моделей машинного и/или глубокого обучения и применению к исходным данным алгоритмов калибровки цвета.

Библиографический список

1. Mesa, A. R. Multi-input deep learning model with RGB and hyperspectral imaging for banana grading / A. R. Mesa, J. Y. Chiang // Agriculture. – 2021. – Vol. 11. – No. 8. – P. 687.
2. Septiarini, A. Machine vision for the maturity classification of oil palm fresh fruit bunches based on color and texture features / A. Septiarin, A. Sunyoto, H. Hamdania et al. // Scientia Horticulturae. – 2021. – Vol. 286. – P. 110245.
3. Cho, B. H. Potential of Snapshot-Type Hyperspectral Imagery Using Support Vector Classifier for the Classification of Tomatoes Maturity / B. H. Cho, Y. H. Kim, K. B. Lee et al. // Sensors. – 2022. – Vol. 22. – No. 12. – P. 4378.

4. Kumar, S. D. A microcontroller based machine vision approach for tomato grading and sorting using SVM classifier / S. D. Kumar, S. Esakkiraja, S. Bama, B. Keerthiveena // Microprocessors and Microsystems. – 2020. – Vol. 76. – P. 103090.
5. de Luna, R. G. Tomato growth stage monitoring for smart farm using deep transfer learning with machine learning-based maturity grading / R. G. de Luna, E. P. Dadio, A. A. Bandala, R. R. P. Vicerra // AGRIVITA, Journal of Agricultural Science. – 2020. – Vol. 42. – No. 1. – P. 24-36.
6. Bautista, J. F. Automated Sorter and Grading of Tomatoes using Image Analysis and Deep Learning Techniques / J. F. Bautista, C.D. Oceñ, M. J. Cabreros, S. P. L. Alagao // 2020 IEEE 12th International Conference on Humanoid, Nanotechnology, Information Technology, Communication and Control, Environment, and Management (HNICEM). – IEEE, 2020. – P. 1-6.
7. Das, P. Automated tomato maturity grading system using CNN / P. Das, J. P. S. Yadav // 2020 International Conference on Smart Electronics and Communication (ICOSEC). – IEEE, 2020. – P. 136-142.
8. Cheng, H. K. Cascadepsp: Toward class-agnostic and very high-resolution segmentation via global and local refinement / H. K. Cheng, J. Chung, Y. W. Tai, C. K. Tang // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. – 2020. – P. 8890-8899.